

ADS2笔记整理

[Overview](#)

[Reminders](#)

[Windows Operations](#)

[Basic Setup](#)

[Data Import, Exploration & Cleaning](#)

[Import](#)

[Explore](#)

[Cleaning checklist](#)

[Visualization](#)

[T-test](#)

[选择流程 \(ask one by one\)](#)

[Check assumptions](#)

[Run](#)

[Report 模板](#)

[ANOVA](#)

[类别选择 \(Type selection\)](#)

[假设检验 \(Check assumptions\)](#)

[1-way ANOVA](#)

[2-way ANOVA](#)

[结果解读三件套](#)

[Correlation & Regression](#)

[Correlation \(相关\) vs Regression \(回归\)](#)

[Regression 假设检验](#)

[代码](#)

[r 值解读](#)

[多变量优化 \(step-wise\)](#)

[Bootstrapping](#)

[何时使用](#)

[核心原则](#) ⚠️

[Hypothesis testing 模板](#)

[CI 模板 \(95%\)](#)

[Chi-Squared / Fisher's Exact Test \(类别数据\)](#)

[选择速查](#)

[代码速查](#)

[3-way 自由度](#)

[Bayesian Statistics \(贝叶斯\)](#)

[核心公式](#)

[经典案例：医学检测](#)

[Specificity vs Sensitivity](#) ★

[多假设比较 \(Bayes Factor\)](#)

[Probability 函数四件套](#)

[Time Series \(时间序列\)](#)

[核心模型](#)

[构建与可视化](#)

[处理时间数据](#) ★ (考点)

[趋势检验 + 分解 + 预测](#)

[Power Analysis \(功效分析\)](#)

[影响因素](#)

[α / β 平衡](#)

[代码 \(built-in\)](#)

[模拟法 \(Simulation\)](#)

[Hypothesis Testing 矩阵 \(核心概念\)](#)

[Critical Thinking & Future Directions \(实验改进 / 论述题套话\)](#)

[Cheat Sheet \(代码速查\)](#)

[tidyverse 三件套](#)

[R as a calculator](#)

[决策流程图 \(Flow chart\) 关键节点](#)

🔴 补充 1 | [完整对偶速查 \(Parametric ↔ Non-parametric, Paired ↔ Unpaired\)](#)

[1.1 T-test / 两组比较 完整矩阵](#)

[1.2 ANOVA / 多组比较 完整矩阵](#)

[Post-hoc 完整对照](#)

[1.3 Correlation & Regression 完整矩阵](#)

[1.4 Categorical Data 完整矩阵 \(χ² 家族\)](#)

[1.5 Bootstrapping 完整使用场景 \(你已有基础, 此处补对偶\)](#)

🔴 补充 2 | [Cluster Analysis \(聚类分析\) — S2 考点, 原笔记缺失](#)

[主流方法](#)

必备前处理

评估聚类质量

🔥 补充 3 | ADS2 S2 开卷考试速查 (Exam Prep)

3.1 考试结构 & 评分权重

3.2 考前必备物 (Open-book 不等于 look up everything)

3.3 考场可用 R 包 (无网络默认装好)

3.4 题目 Clue 识别表 ★ (Dmytro 明确点出)

3.5 标准报告 / 讨论 4 段式模板 ★

3.6 Power Analysis 决策流程 ★

3.7 R Markdown / knitr 排雷手册 ★

3.8 R Markdown 文件格式规则 (Dmytro 强调)

3.9 备考练习数据集 (Dmytro 推荐)

3.10 终极决策流程图 (考场速查)

🔥 补充 4 | 方法选择与逻辑思辨 (Method Selection Logic) ★★★★★

4.1 核心思辨原则

原则 A: 扩大 sample size ≠ 万能答案 ⚠️

原则 B: 选检验前先回答 5 个问题

原则 C: 每个方法都有「代价」

4.2 方法选择决策树 (按问题类型组织) ★

Q1: 两组比较 (Difference)

Q2: 多组比较 (Multi-group)

Q3: 关联 / 预测 (Relationship)

Q4: 类别数据 (Categorical)

4.3 完整分析流程 8 步 (Pipeline Checklist) ★★

Step 1 — Import & Inspect

Step 2 — Clean

Step 3 — Exploratory Plot (EDA)

Step 4 — Formulate Hypotheses ★

Step 5 — Check Assumptions ★

Step 6 — Run Test

Step 7 — Post-hoc + Effect Size + CI ★

Step 8 — Interpret & Discuss ★

4.4 常见扣分点 (Dmytro 隐性 rubric)

4.5 「改进方向」答题套话 (替代 "sample size") ★

1 实验设计 (Design)

2 抽样 (Sampling)

3 测量与控制 (Measurement & Control)

4 分析方法 (Analysis)


5 机制深入 (Mechanism)

4.6 「为什么选 / 不选」论证模板 ★

4.7 整体逻辑框架一图流 (考场最后一遍过)

Overview

Flow Chart for Selecting Commonly Used Statistical Tests



Reminders

- It is of extreme importance to notice if **the data is paired**, e.g., one before drug injection one after drug injection. If so, only the difference between two time points are meant to be used. So you should calculate it correspondingly.
- One hack of re-structuring data during *data cleaning* is to let the **independent** variables be **column names**, while dependent variables be the **filling values**.
- All the plots must be **colored**.
- Just **don't** choose Kruskal-Wallis test when running ANOVA.
- ANOVA plots = **boxplot/violin** plot (preferred, go visit www.r-graph-gallery.com)
- 检查代码块knit完之后有没有超出边框（特别是用tidyverse管道符和#注释的时候）

Windows Operations

- Open exam paper in **edge** browser, DO NOT open in Chrome
- Get the to-import file path
 - Unzip the file onto the desktop
 - The file path is on the upper path bar
 - When importing into R, replace the "\" to "/"
- When the blinking input cursor turns into this: `_`, hit the button on the right upper keyboard

Basic Setup

1. first check the working directory using `getwd()`, if direct to wrong path, use `setwd()`
2. create a R markdown, choose *pdf* knitted (this can be changed in the very first chunk of code)
3. Set `"Last knitting time": Sys.time()` (recommended)
4. Run: `install.packages("summarytools")` (this code can be used in case any packages are not downloaded)
5. Edit setup chunk

```
{r setup, include=FALSE, message=FALSE} # include false -> not show anything
# message false -> not show the info like package loading etc.
knitr::opts_chunk$set (
  echo = TRUE,
  message = FALSE,
  warning = FALSE
) # this part is globally effective
library(summarytools)
library(tidyverse)
library(ggplot2)
library(deSolve) # 注意: 是 deSolve 不是 ddSolve
library(expm)
```

6. Chunk option 速查

- `{r}` = `{r eval=T, echo=T}`: 默认
- `{r eval=T, echo=F}`: 导入数据时用 (运行但不显示代码)
- `{r, cache=T}`: 保存运行结果, 避免重复跑耗时代码
- `include=FALSE`: 跑代码但全部不显示 (最适合 setup chunk)
- `results='hide'`: 只隐藏文本输出, 图照常显示

Data Import, Exploration & Cleaning

Import

```
data <- read.table(file = "", header = TRUE, sep = "\t") # .tsv / .txt
data <- read_csv(file = "", col_names = TRUE)           # .csv
data("cars"); Cars <- cars                             # built-in
```

Explore

```
str(data); head(data); table(data$col)                  # head() 必须出现在 report
dfSummary(data, graph.col = TRUE, style = "grid") %>% stview() # 自我探索 (echo=F)
```

Cleaning checklist

1. Remove unnecessary cols: `data <- data[, -x]`
2. NAs:

```
anyNA(data)
which(is.na(data), arr.ind = TRUE)
data <- data[complete.cases(data), ] # 或 df %>% drop_na()
```

3. Duplications: `data <- data[!duplicated(data), ]`
4. Typos (错别字): `table(data$col)` 看异常 → 定位 → 替换
5. Long ↔ Wide (宽长转换):

```
df_wide <- df_long %>% pivot_wider(names_from = Measurement, values_from = Glucose)
df_long <- df_wide %>% pivot_longer(cols = starts_with("Glucose"),
                                   names_to = "Measurement", values_to = "Glucose")
```

6. **Rename:** `df %>% rename(NewName = OldName)`

7. **Convert types (类型转换):** 自变量必须是 `factor`

```
data <- data %>% mutate(col = factor(col, levels = c(0.5, 1, 2), ordered = TRUE))
```

8. **Outliers (离群值):** `plot(density(data$col), lwd = 3)`

Visualization

自变量类型	推荐图
分类 X + 连续 Y (unpaired)	Boxplot, Whisker plot, Strip chart
分类 X + 连续 Y (paired)	Boxplot of differences, Strip + linked points
分类 X + 分类 Y	Bar chart, 百分比 table, Pie chart
连续 X	2D Scatter + Trend line

常用资源 (Recommended sites):

- r-graph-gallery.com — 各类图形示例库
- statisticsbyjim.com — 统计概念
- statology.org — R 操作 walk-through
- r2e.com — R Cookbook 2nd Ed (markdown + stat 详细)
- intro2r.com — markdown 友好, 可直接复制
- r-charts.com — 图表选择器
- statisticsglobe.com — 注意 Errors & Warnings 板块
- tidyverse.org — tidyverse 全家桶官方

T-test

选择流程 (ask one by one)

1. 1 sample vs value? **or** 2 samples?
2. (2-sample) Variances equal? → Yes: Student's; No: Welch's
3. 比较方向是否说明? → Yes: 1-tailed; No: 2-tailed
4. (2-sample) 同一对象不同时间点? → Yes: paired
5. Normality 满足? → No: 非参 (Wilcoxon signed-rank / Mann-Whitney U)

Check assumptions

```
shapiro.test(data$col)           # p > 0.05: 满足正态
qqnorm(data$col); qqline(data$col, col = "red", lwd = 3)
var.test(data$col1, data$col2)    # 方差齐性 F-test
```

Run

```
t.test(x, y = NULL, alternative = c("two.sided", "less", "greater"),
       mu = 0, paired = FALSE, var.equal = FALSE)
# 非参替代
wilcox.test(..., paired = TRUE)    # Wilcoxon signed-rank
wilcox.test(..., paired = FALSE)   # Mann-Whitney U
```

Report 模板

| There was a [increase/decrease] of X (M = 8.7, SD = 3.1) compared to Y (M = 3.2, SD = 1.5), $t(52) = 4.8$, $p < 0.001$.

ANOVA

类别选择 (Type selection)

类型	自变量数	研究问题
One-way (单因素)	1 个 factor	各组均值是否有差异
Two-way (双因素)	2 个 factor	主效应 A、主效应 B、A×B 交互
Factorial	≥ 2	多因素+复杂交互 (不太考)

假设检验 (Check assumptions)

假设	不满足时	R 代码
正态性	Kruskal-Wallis (但本课不选!)	<code>shapiro.test(residuals(model))</code> 或 <code>plot(model, 2)</code>
方差齐性	Welch's ANOVA (<code>var.equal = FALSE</code>)	<code>car::leveneTest(y ~ group, data)</code> ($p > 0.05$ 满足)
独立性	重复测量 / 混合模型 <code>lmer()</code>	实验设计决定

1-way ANOVA

```
# 可视化
ggplot(data, aes(x = Group, y = Value)) +
  geom_boxplot() + geom_jitter(width = 0.1, alpha = 0.5) + theme_minimal()

# 建模
model <- aov(Value ~ Group, data = data)
plot(model, 1); plot(model, 2)      # 残差图 + Q-Q
shapiro.test(resid(model))          # 正态性
summary(model)                      # F, p

# 事后检验 (即使没要求也要做!)
TukeyHSD(model)
```

2-way ANOVA

```
model <- aov(weight_gain ~ genotype * diet, data = mouse) # 含交互
model <- aov(weight_gain ~ genotype + diet, data = mouse) # 不含交互
summary(model); TukeyHSD(model)
```

结果解读三件套

- **Main effect A:** A 的不同水平间均值显著差异
- **Main effect B:** 同上
- **Interaction:** A 的效应是否依赖于 B 的水平
- 效应量: η^2 (eta squared, 0.01/0.06/0.14 = 小/中/大), Cohen's f (0.1/0.25/0.4)

Correlation & Regression

Correlation (相关) vs Regression (回归)

- **Correlation:** 看 r^2 , 两变量关联强度, 不区分自/因变量
- **Regression:** 严格区分 自变量(predictor) vs 因变量(response)

Regression 假设检验

假设	R 中检查	违反办法
1. 线性关系	<code>plot(model, 1)</code> 残差无曲线趋势	加二次项 X^2 , 或非线性模型
2. 方差齐性	<code>plot(model, 1)</code> 红线水平; <code>lmtest::bptest(model)</code>	对 Y 取 <code>log()</code> , 加权最小二乘
3. 残差正态	<code>plot(model, 2)</code> Q-Q 图; <code>shapiro.test(resid(model))</code>	Spearman 相关, 非参
4. 独立性	实验设计 / <code>plot(resid(model))</code> 看顺序	混合模型 <code>lmer()</code>

代码

```

model <- lm(Weight ~ Age, data = Mice_WT)
summary(model)
# (Intercept) 行 → 检验截距是否显著 ≠ 0
# Age 行 → 检验斜率是否显著 ≠ 0
# F-statistic → 模型整体显著性
# Multiple R-squared → x 解释 y 多少方差

plot(cooks.distance(model), type = "h") # 离群点检查
predict.lm(model, newdata = data.frame(Age = c(10, 12, 14))) # 预测
cor.test(x, y, method = "pearson") # 假设满足
cor.test(x, y, method = "spearman") # 假设不满足

```

r 值解读

- $|r| < 0.3$: 弱 (weak)
- $0.3 \leq |r| < 0.5$: 中 (moderate)
- $0.5 \leq |r| < 0.7$: 强 (strong)
- $0.7 \leq |r| \leq 1$: 很强 (very strong)

多变量优化 (step-wise)

```

model_1 <- lm(weight ~ age, data = df)
model_full <- lm(weight ~ age + height + sex + diet, data = df)
step(object = model_1, direction = "forward", scope = formula(model_full))

```

Bootstrapping

何时使用

- 不知道总体分布; 分布复杂/非正态; 总体极小; 数据缺乏独立性; 类别非互斥

核心原则

- 有放回抽样 (`replace = TRUE`)
- sample size 必须 = 原数据集总量 (e.g. 实验组 n=20 + 对照 n=20 → sample size = 40)

Hypothesis testing 模板

```

set.seed(123)
bootstrap_record <- vector()
for (a in 1:10000) {
  boot_g1 <- median(sample(data$col, n_g1, replace = TRUE))
  boot_g2 <- median(sample(data$col, n_g2, replace = TRUE))
  bootstrap_record <- c(bootstrap_record, boot_g1 - boot_g2)
}
hist(bootstrap_record); abline(v = observed_diff, col = "red")
# p-value = bootstrap 中比观测值更极端的比例
length(subset(bootstrap_record, bootstrap_record >= observed_diff)) / length(bootstrap_record)

```

CI 模板 (95%)

```

lower_bound <- quantile(bootstrap_record, 0.025)
upper_bound <- quantile(bootstrap_record, 0.975)
# 两组 CI 不重叠 → 显著差异 (p < 0.05)

```

Chi-Squared / Fisher's Exact Test (类别数据)

选择速查

变量类型	目的	检验
单分类	比例是否符合预期	拟合优度 χ^2 (Goodness-of-Fit)
两个分类 (大样本)	是否独立 / 同质	独立性 χ^2 / 同质性 χ^2
两个分类 (任一格 < 5 或一类 < 20)	同上	Fisher's exact test
三个分类	三向关联	3-way χ^2

代码速查

```

tab <- table(row_var, col_var)
chisq.test(tab) # 主检验
chisq.test(tab)$expected # 期望频数 (≥ 5 才能用  $\chi^2$ )
chisq.test(tab)$stdres # 标准化残差
chisq.test(c(40, 30, 18, 28), p = rep(0.25, 4)) # Goodness-of-Fit
fisher.test(tab) # 小样本
library(effects); cramers_v(tab) # 效应量

```

3-way 自由度

- $df = (A)(B)(C) - 1 - (A-1) - (B-1) - (C-1)$

Bayesian Statistics (贝叶斯)

核心公式

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)} = \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|\neg A)P(\neg A)}$$

- **Prior** $P(H)$: 先验信念 (基于以往经验的初始 belief)
- **Likelihood** $P(\text{data} | H)$: 在假设 H 下观察到数据的概率
- **Posterior** $P(H | \text{data})$: 看到数据后更新的信念 (= prior × likelihood / marginal)
- **Marginal** $P(\text{data})$: 数据的总概率, θ -independent 归一化常数

经典案例：医学检测

```

prior <- 0.01 # 患病率
likelihood <- 0.99 # 真阳性率
false_positive <- 0.05
posterior <- (likelihood * prior) /
              (likelihood * prior + false_positive * (1 - prior))
# ≈ 0.166 → 即使阳性, 真患病概率仅 16.6%

```

Specificity vs Sensitivity ★

- **Sensitivity (敏感性)** = True Positive Rate = $TP / (TP + FN)$ — 检出真阳性的能力
- **Specificity (特异性)** = True Negative Rate = $TN / (TN + FP)$ — 排除真阴性的能力
- **Odds**: $P(A) / P(\neg A)$; **Odds Ratio** = $Odds_1 / Odds_2$

多假设比较 (Bayes Factor)

```

P_data_H1 <- dbinom(18, size = 53, prob = 0.35)
P_data_H0 <- dbinom(18, size = 53, prob = 0.25)
BF_H1_H0 <- P_data_H1 / P_data_H0 # BF = 10 → H1 比 H0 likely 10 倍

```

Probability 函数四件套

前缀	含义	例 (Binomial)
r...	随机抽样	<code>rbinom(n, size, prob)</code>
d...	密度/概率	<code>dbinom(x, size, prob)</code>

前缀	含义	例 (Binomial)
p...	累积概率	<code>pbinom(q, size, prob)</code>
q...	分位数	<code>qbinom(p, size, prob)</code>

Time Series (时间序列)

核心模型

$$Y_t = \text{Trend}_t + \text{Seasonal}_t + \text{Remainder}_t$$

构建与可视化

```
library(stats); library(forecast)
ts_data <- ts(orig_data, start = c(1974, 1), frequency = 12)
# frequency: 12=月度, 4=季度, 1=年度
plot(ts_data, col = "blue", lwd = 2)
```

处理时间数据 ★ (考点)

```
# 转换
date1 <- as.Date("2024-03-15")           # 标准格式
date2 <- as.Date("15/03/2024", format = "%d/%m/%Y") # 非标准
dt <- as.POSIXct("2024-03-15 14:30:00")   # 带时间

# 加减
d1 + 7                                     # 7 天后
time_diff <- d2 - d1                      # difftime, days
difftime(d2, d1, units = "weeks")         # 也可 "hours"
```

趋势检验 + 分解 + 预测

```
ts_lm <- lm(ts_data ~ time(ts_data)); summary(ts_lm) # p < 0.05 → 趋势显著
acf(ts_data)                                       # 自相关 → 看周期性
ts_decomp <- decompose(ts_data); plot(ts_decomp)  # 加法分解

# 预测
future_time <- time(ts_data)[length(ts_data)] + seq(1, 10)
future_pred <- predict(ts_lm, newdata = data.frame(time.ts_data = future_time))
lines(future_time, future_pred, col = "red", lwd = 2)

# 改进: 趋势 + ARIMA 残差
residuals_arima <- auto.arima(resid(ts_lm))
future_resid <- forecast(residuals_arima, h = 10)$mean
future_combined <- future_pred + future_resid
```

Power Analysis (功效分析)

影响因素

- Effect size $\Delta\mu \uparrow \rightarrow \text{power} \uparrow$
- $\sigma \uparrow \rightarrow \text{power} \downarrow$
- $n \uparrow \rightarrow \text{SEM} \downarrow \rightarrow \text{power} \uparrow$
- $\alpha \uparrow \rightarrow \beta \downarrow \rightarrow \text{power} \uparrow$

α / β 平衡

- 临床 III 期: power = 0.9-0.95, $n \geq 80$
- 动物实验: power = 0.8 ($\beta = 0.2$)
- 组学: 追求高 power 以减少 II 类错误

代码 (built-in)

```
power.t.test(n = 5, delta = 7.82, sd = 8.2, sig.level = 0.05, type = "paired")
power.t.test(power = 0.8, delta = 7.82, sd = 8.2, sig.level = 0.05, type = "two.sample")
# ANOVA
library(pwr)
pwr.anova.test(k = 3, n = 20, f = 0.25, sig.level = 0.05)      # 计算 power
pwr.anova.test(k = 3, f = 0.25, sig.level = 0.05, power = 0.8) # 计算 n
```

模拟法 (Simulation)

```
ps <- replicate(1e5, t.test(rnorm(5, 7.82, 8.2), mu = 0)$p.value)
power <- length(which(ps < 0.05)) / 1e5
```

Hypothesis Testing 矩阵 (核心概念)

	H ₀ true	H _a true
Test 显著	V = α (Type I, False Positive)	S = Power = $1 - \beta$ (True Positive)
Test 非显著	U = Specificity (True Negative)	T = β (Type II, False Negative)

- FPR = $\alpha = V/(V+U)$
- TPR = Sensitivity = $S/(S+T)$
- FDR = $V/(V+S)$

Critical Thinking & Future Directions (实验改进 / 论述题套话)

- Sampling:** Stratified 抽样保证多样性, 避免 confounding
- Controls:** 阳性/阴性对照, refine control group similarity
- Bias control:** Randomization, double-blinding
- Design:** Longitudinal (跟踪时间动态), Dose-response (机制深度)
- Mechanism:** Western blot, IHC, RNAi, CRISPR/Cas9, scRNA-seq DEGs
- Stopping rules:** 防止 p-hacking; ethical sample size 不过大不过小
- Bootstrapping caveat:** "data is incomplete, fundamentally not exact, but it is all we have"

Cheat Sheet (代码速查)

tidyverse 三件套

```
# dplyr - 数据操作
data %>% filter(col > 5) %>% select(col1, col2) %>%
  mutate(new = col1 * 2) %>% group_by(g) %>% summarise(m = mean(col1)) %>%
  arrange(desc(m))

# tidyr - 数据整形
pivot_longer(cols, names_to, values_to)
pivot_wider(names_from, values_from)
drop_na(); separate(col, into = c("a", "b"), sep = "_")

# data.table - 大数据快
library(data.table); dt <- as.data.table(data)
dt[col > 5, .(mean(x)), by = group] # 行筛选, 列计算, 分组
```

R as a calculator

```
10 %% 3      # 余数 = 1
10 %/% 3     # 整除 = 3
log(x, base = 2); log10(1000); exp(1)
```

```

solve(m) # 矩阵求逆
eigen(m)$values; eigen(m)$vectors # 特征值/向量
A %*% B # 矩阵乘法
uniroot(function(x) x^2 - 3*x + 2, c(0, 3))$root # 解方程

```

决策流程图 (Flow chart) 关键节点

1. 数据类型 → Continuous (t/ANOVA) / Categorical (χ^2)
2. 问题类型 → Relationship (cor/lm) / Difference (t/ANOVA)
3. 组数 → 2 (t-test) / >2 (ANOVA)
4. 参数假设满足? → Yes 参数 / No 转换 → 仍不行 → 非参
5. ANOVA 显著 → Tukey HSD post-hoc

📌 补充 1 | 完整对偶速查 (Parametric ↔ Non-parametric, Paired ↔ Unpaired)

结合 Dmytro 的考前指导 + Yuxin 复习要点。原笔记多处只列出了 parametric / unpaired 的版本，此处补齐对偶。

1.1 T-test / 两组比较 完整矩阵

设计 (Design)	Parametric (正态满足)	Non-parametric (违反正态)	R 代码
1-sample vs 常数 μ_0	One-sample t-test	Wilcoxon signed-rank (1-sample)	<code>t.test(x, mu=0)</code> / <code>wilcox.test(x, mu=0)</code>
2-sample unpaired • 方差齐	Student's t-test	Mann-Whitney U (= Wilcoxon rank-sum)	<code>t.test(x,y,var.equal=TRUE)</code> / <code>wilcox.test(x,y,paired=FALSE)</code>
2-sample unpaired • 方差不齐	Welch's t-test (R 默认)	Mann-Whitney U (对方差不敏感)	<code>t.test(x,y,var.equal=FALSE)</code>
2-sample paired (前后/配对)	Paired t-test	Wilcoxon signed-rank test (paired)	<code>t.test(x,y,paired=TRUE)</code> / <code>wilcox.test(x,y,paired=TRUE)</code>

- ⚠️ 判定 **paired** 的关键：同一受试者在不同时间点 / 同一配对单元（左右眼、孪生子）。Dmytro 强调 **paired** 数据只能算差值再分析。
- One-sided vs two-sided: Dmytro 提示 *correctly* 用单尾能提升 power，但必须**实验前**就有方向性预设（避免 p-hacking）。

1.2 ANOVA / 多组比较 完整矩阵

设计 (Design)	Parametric	Non-parametric	方差不齐时	R 代码
One-way unpaired (1 因素, 独立样本)	One-way ANOVA	Kruskal-Wallis test ⚠️	Welch's ANOVA <code>oneway.test(var.equal=FALSE)</code>	<code>aov(y~g)</code> / <code>kruskal.test(y~g)</code>
One-way paired / 重复测量 (Repeated Measures, RM)	Repeated Measures ANOVA	Friedman test	混合线性模型 <code>lmer()</code> (lme4)	<code>aov(y~g+Error(subject/g))</code> / <code>friedman.test(y,g,subject)</code>
Two-way unpaired (2 因素 + 交互)	Two-way ANOVA	Scheirer-Ray-Hare test (rare); 或对每因素 KW	Robust ANOVA <code>WRS2::t2way()</code>	<code>aov(y~A*B)</code>
Mixed design (between + within)	Mixed ANOVA / <code>ezANOVA</code>	—	<code>lmer()</code> 混合模型	<code>afex::aov_ez()</code>

⚠️ 本课 **Kruskal-Wallis** 不被推荐（你已记录），但 Dmytro 在 S2 大纲中明确包含 "parametric **and** non-parametric ANOVA" → 考试可能要求你识别何时该用非参（正态严重违反 + 样本极小）。若题目要求 "non-parametric ANOVA"，仍要会写 `kruskal.test()`。

Post-hoc 完整对照

主检验	常用 Post-hoc	R 代码
One-way ANOVA (方差齐)	Tukey HSD	<code>TukeyHSD(model)</code>
One-way ANOVA (方差不齐)	Games-Howell	<code>rstatix::games_howell_test()</code>
Two-way ANOVA	Tukey HSD on each factor / simple effects	<code>TukeyHSD(model)</code> 或 <code>emmeans::emmeans()</code>
Repeated Measures	Pairwise paired t-test + Bonferroni	<code>pairwise.t.test(y,g,paired=TRUE,p.adjust="bonferroni")</code>
Kruskal-Wallis	Dunn's test (with Bonferroni/Holm)	<code>FSA::dunnTest()</code> 或 <code>dunn.test::dunn.test()</code>
Friedman	Pairwise Wilcoxon signed-rank + Bonferroni	<code>pairwise.wilcox.test(...,paired=TRUE)</code>

1.3 Correlation & Regression 完整矩阵

目的	Parametric	Non-parametric / 稳健	关键代码
两连续变量相关	Pearson r (线性 + 正态)	Spearman ρ (秩相关, 单调即可); Kendall τ (小样本 / 多 ties 时更稳健)	<code>cor.test(x,y,method="pearson/spearman/kendall")</code>
X → Y 预测建模	线性回归 <code>lm()</code> (4 大假设)	Rank-based regression <code>Rfit::rfit()</code> ; Theil-Sen <code>mblm::mblm()</code> ; Robust <code>MASS::rlm()</code>	—
残差非正态 / 异方差	—	Bootstrap CI for slope (考点!); 对 Y 取 <code>log()</code> / <code>sqrt()</code>	<code>boot::boot()</code> 或手写 for 循环
计数 / 二项 Y	—	GLM : <code>glm(y~x, family=poisson/binomial)</code>	—

💡 Dmytro 的考点暗示: 题目若说 "残差严重偏态" → 选 Spearman 相关 或 bootstrap slope CI, 而不是硬上 lm。

1.4 Categorical Data 完整矩阵 (χ^2 家族)

设计	大样本 (期望 ≥ 5)	小样本 / 期望 < 5	Paired / 配对 类别数据
1 个变量 vs 理论比例	χ^2 Goodness-of-Fit	Exact binomial / multinomial test	—
2 个变量独立性 (2×2)	χ^2 + Yates' continuity correction (R 默认)	Fisher's exact test	McNemar's test ⚠️ (e.g. 同一人前后态度)
2 个变量独立性 (R×C)	Pearson χ^2	Fisher (<code>simulate.p.value=TRUE</code>)	Cochran's Q test (k 个配对二分类)
分层 / 控制混杂	Cochran-Mantel-Haenszel <code>mantelhaen.test()</code>	—	—

```
# McNemar (paired categorical) — 重要漏点!
mcnemar.test(matrix(c(a,b,c,d), nrow=2)) # b, c 是不一致格
# Yates correction (R 中 2×2 默认自动开启, 显式: correct=TRUE)
chisq.test(tab, correct = TRUE)
# Fisher 大列联表
fisher.test(tab, simulate.p.value = TRUE, B = 10000)
```

1.5 Bootstrapping 完整使用场景 (你已有基础, 此处补对偶)

- **Hypothesis testing** 版: 已有
- **CI 版** (parametric CI 的非参替代): 已有
- ★ **补充: paired bootstrap** — 对 paired 数据, 每次抽样应**整对 (subject)** 而非两列独立抽

```
idx <- sample(1:n, n, replace = TRUE)
boot_diff <- median(post[idx] - pre[idx]) # 保持配对结构
```

- ★ **补充: stratified bootstrap** — 各组分别抽 (类别比例敏感时)
- **vs Permutation test**: bootstrap 估计 sampling distribution; permutation 估计 null distribution → 检验差异更纯粹

📌 补充 2 | Cluster Analysis (聚类分析) — S2 考点, 原笔记缺失

Dmytro 在 S2 大纲中明确包含 "Cluster analysis — be able to do the basic approaches in R"

主流方法

方法	核心思想	R 代码	选择 K / cut 的依据
K-means	最小化簇内 SS, 需预设 K, 对球形簇敏感	<code>kmeans(scale(X), centers=3, nstart=25)</code>	Elbow plot (<code>fviz_nbclust(X,kmeans,"wss")</code>), Silhouette
Hierarchical (层次聚类)	自底向上合并 (agglomerative)	<code>hclust(dist(scale(X)), method="ward.D2")</code>	Dendrogram • <code>cutree(h, k=3)</code>
PCA (预处理 / 降维可视化)	正交主成分	<code>prcomp(X, scale.=TRUE)</code>	scree plot (碎石图)

必备前处理

1. `scale()` **标准化** — 距离对量纲敏感; 不标准化会被大尺度变量主导
2. **选择距离**: `dist(X, method = "euclidean"/"manhattan"/"correlation")`
3. **Linkage 方法** (hclust): "ward.D2" (常用), "complete", "average", "single" (链效应)

评估聚类质量

- **Silhouette score** $\in [-1, 1]$, 越大越好: `cluster::silhouette()`

- Gap statistic: `cluster::clusGap()`
- 可视化: `factoextra::fviz_cluster()`

📌 补充 3 | ADS2 S2 开卷考试速查 (Exam Prep)

3.1 考试结构 & 评分权重

- 3 个 problems × 25% = 75% (不仅是 coding, 还含解释 / 假设 / 讨论)
- R Markdown 文档质量 25% (排版 / 注释 / knitr 成功)
- 时长 3 小时, 完全开卷, 无限制

3.2 考前必备物 (Open-book 不等于 look up everything)

- ☒ 可加载的本地 .Rmd 模板 (能直接 knitr PDF)
- ☒ 常用代码片段 cheat sheet (上面的对偶矩阵全打印)
- ☒ 每个 test 的 assumption 检查代码块
- ☒ 熟悉 Blackboard 提交流程

3.3 考场可用 R 包 (无网络默认装好)

```
library(tidyverse) # dplyr, ggplot2, tidyr...
library(rmarkdown); library(knitr); library(tinytex)
library(pwr) # power analysis
# 其他可从 CRAN 现场安装 (有镜像)
```

3.4 题目 Clue 识别表 ★ (Dmytro 明确点出)

题目关键词	要做什么 / 隐藏点
"Import and clean ... if inconsistencies are available"	数据脏! 必须 NA / duplication / typo / 类型转换
"Plot it in a way that addresses the question"	选 plot 类型要 match 自变量类型 (见 \$Visualization)
"Choose the test, explain choice, formulate hypotheses, check assumptions"	4 件套必须显式写出 — 不写就扣分
"Name at least N improvements / follow-ups"	不要只说 sample size! 要给临床/机制角度 + 用 power analysis 支撑
"No need to do X" / "Do this in a certain way"	严格遵守, 偏离会扣分

3.5 标准报告 / 讨论 4 段式模板 ★

1. **Formal stats summary** — 检验统计量 + df + p-value + **effect size** (Cohen's d / η^2 / Cramer's V) + CI

A paired t-test showed a significant decrease in BP after treatment ($M_{diff} = -8.2$ mmHg, 95% CI [-10.1, -6.3], $t(29) = -8.7$, $p < 0.001$, Cohen's d = 1.6).

2. **Biological / clinical interpretation** — what does it mean? 与机制 / 已有文献联系
3. **Limitations beyond sample size** — 没做的 control? 混杂未控? 机制不清? Selection bias?
4. **Power analysis-backed sample size recommendation** — 用 `pwr.*` 给具体数, 不要凭感觉

3.6 Power Analysis 决策流程 ★

```
现在 p > 0.05 (H0 保留)
├─ 算当前 power (pwr.* 给定 n, effect, α)
│   └─ power ≥ 0.8 → "sample size 足够, 不需要更多"
│       └─ power < 0.8 → "power 不足 = X.XX, 需扩样到 n=YY 才能达 0.8"
现在 p < 0.05 (H0 拒绝)
└─ 通常无需扩样; 反而该讨论 effect size 是否有临床意义
```

3.7 R Markdown / knitr 排雷手册 ★

- ☒ **YAML** 加 `keep_md: true` 和 `keep_tex: true` (出错可定位)
- ☒ **PDF 失败** → 立即降级到 **HTML 或 DOCX**, 不要现场修 LaTeX
- ☒ **不要碰 tlmgr / texlive** (考场禁忌!)
- ☒ **xfun 包出错** → 卸载重装 `remove.packages("xfun"); install.packages("xfun")`
- ☒ **代码块超出边框** → `tidy=TRUE, tidy.opts=list(width.cutoff=60)` 或手动换行
- ☒ **遇到错** → 把文档对半砍逐块定位
- ☒ **实在 knitr 不出来** → 提交 .Rmd + .R 也是分

3.8 R Markdown 文件格式规则 (Dmytro 强调)

- 块与块之间必须留空行 (header / 代码块 / 段落都要)
- **# 后必须有空格**: `# Title` ☒ vs `#Title` ☒
- 代码块前后空行, 否则会被合并到段落
- 中文字符可能让 LaTeX 报错 → YAML 加 `header-includes: \\usepackage{ctex}` 或换 HTML 输出

3.9 备考练习数据集 (Dmytro 推荐)

```
data("Indometh")      # paired data, RM-ANOVA 练习
data("ToothGrowth")    # 2-way factorial ANOVA
data("diamonds")       # 大数据 + 多种分析
data("cars")           # 简单回归 + 相关
data("iris")           # 分类 / 聚类 / PCA 全能
library("datarium")    # 大量统计教学数据集
```

3.10 终极决策流程图 (考场速查)

1. 数据是什么类型?
 - └ **连续** (Continuous) → 走 **t/ANOVA/回归** 分支
 - └ **类别** (Categorical) → 走 χ^2 /Fisher/McNemar 分支
2. 研究问题?
 - └ **Difference** (比较) → **t / ANOVA / Mann-Whitney / Kruskal**
 - └ **Relationship** (关联) → **cor / lm / Spearman / Kendall**
3. 样本设计?
 - └ **Independent** (独立 / unpaired) → 标准版本
 - └ **Paired / Repeated** → **paired t / RM-ANOVA / Wilcoxon signed-rank / Friedman / McNemar**
4. Parametric 假设是否满足? (Shapiro + Levene + 残差图)
 - └ 满足 → 参数检验
 - └ 仅方差不齐 → Welch's 版本
 - └ 严重违反 → 非参检验 **OR** Bootstrap **OR** transformation
5. **ANOVA / χ^2 显著** → 必做 **post-hoc** (Tukey / Dunn / Bonferroni)
6. **所有报告必须含**: **stat + df + p + effect size + CI + 生物学解释 + power**

补充 4 | 方法选择与逻辑思辨 (Method Selection Logic) ★★★★★

考试核心: AI 能写对代码, 但选错方法 / 流程不完整 = 直接扣分。本节专注「为什么选这个 test」「为什么不选那个」「整体 pipeline 怎么搭」。

4.1 核心思辨原则

原则 A: 扩大 sample size ≠ 万能答案 ⚠



Dmytro 明确说过: 「不是不可以提扩样, 如果有更好方法你**必须先用别的**。如果你最终选择扩样, 必须说明理由 + 给出 power-backed 的具体 n_0 」

情境	Lazy answer (扩样)	更优解
数据非正态	扩样希望 CLT 救场	Non-parametric / Bootstrap / log 变换
方差不齐	扩样	Welch's t / Welch's ANOVA / robust methods
有离群值	扩样稀释	稳健回归 MASS::rlm() / Spearman / 解释后保留或 winsorize
混杂未控	扩样	Stratification / CMH / ANCOVA / lmer()
effect size 太小	扩样到 $p < 0.05$	承认无临床意义, 不追求统计显著
多组比较 p 不稳	扩样	Post-hoc + 多重比较校正
Power < 0.8 且确实无其他解	✅ 可以扩样	用 pwr * 算出具体 n, 不能凭感觉

原则 B：选检验前先回答 5 个问题

1. Y 是 continuous 还是 categorical?
2. X 有几个、什么类型?
3. 样本是 independent 还是 paired/repeated? ← 最容易被忽略
4. 样本量大小? $n < 30$ 强烈倾向 non-param / Fisher
5. Assumption 实测是否满足? (shapiro + levene + 残差图, 不靠感觉)

原则 C：每个方法都有「代价」

方法	优点 (Pro)	代价 (Con)
Parametric	Power 高, 解释直观	假设违反 → 结论失效
Non-parametric	稳健, 几乎无假设	Power ≈ 参数的 95% (大样本); 小样本可能漏真效应; 检验中位数/秩而非均值
Bootstrap	几乎无假设, 给 CI	需原样本能代表总体; 计算成本; 极小样本仍失效
Data transformation (log/sqrt)	可能恢复正态/方差齐	解释维度改变 (log scale 上的差异 ≠ 原 scale)
扩样	本质上提升 power	最贵 (时间/伦理/钱); 治标不治本

4.2 方法选择决策树 (按问题类型组织) ★

Q1：两组比较 (Difference)



选项	优	劣	何时首选
Student's t	简单 power 高	假设严格	$n \geq 30$ + 正态 + 方差齐
Welch's t	不需方差齐	轻微 power 损失	默认首选 (R 默认)
Mann-Whitney	无分布假设	检验秩/中位数	n 小 + 非正态
Bootstrap	无假设, 直接给 CI	需 set.seed, 慢	分布奇怪 + 想给 CI

Q2：多组比较 (Multi-group)



何时必做 post-hoc:

- ✅ ANOVA / KW / Friedman $p < 0.05$ → 必做 (否则不知道哪两组差)
- ✅ 即使题目没说「做 post-hoc」, 也应主动做并报告
- ❌ $p > 0.05$ → 不做 post-hoc (避免 p-hacking)

- ⚠️ 多重比较必须**矫正**: Bonferroni (保守) / Holm (推荐) / FDR (探索性)

Q3: 关联 / 预测 (Relationship)

```

两变量都连续? —Y→ 线性? —Y→ Pearson r / lm()
                  |
                  |N→ Spearman ρ (单调) / 多项式回归
                  |
                  |N→ X 类别, Y 连续 → ANOVA / t-test
                        X 连续, Y 二分 → Logistic regression (glm binomial)
                        X 连续, Y 计数 → Poisson GLM
  
```

何时选 Spearman 而非 Pearson:

- ✓ 残差非正态
- ✓ 关系单调但非线性 (e.g. logistic 曲线、饱和曲线)
- ✓ 有离群值且不能删
- ✓ 数据本身是 ordinal (等级量表)

Q4: 类别数据 (Categorical)

```

配对 (paired)? —Y→ McNemar (2组) / Cochran's Q (k组)
                  |
                  |N→ 期望频数 ≥5? —Y→ χ² (R 默认 Yates 矫正)
                        |N→ Fisher's exact
                  分层混杂? —Y→ Cochran-Mantel-Haenszel
  
```

4.3 完整分析流程 8 步 (Pipeline Checklist) ★★

 每道题都按这 8 步走，缺一步就丢分。这是 Dmytro 隐性 rubric。

Step 1 — Import & Inspect

- `read_csv()` / `read.table()` → `str()` / `head()` / `dfSummary()`
- 自我确认: 多少行/列? 各列类型? 有无 NA?
- ⚠️ `head()` 必须出现在 report 中

Step 2 — Clean

- NA / duplication / typo / 类型转换 / outlier 可视化 (`plot(density())`)
- ⚠️ 离群值不能盲删 — 先解释原因 (测量错误 / 真实极端) 再决定保留 / 删除 / winsorize
- 自变量必须是 `factor`

Step 3 — Exploratory Plot (EDA)

- 必须有图 (Dmytro: "Plot it in a way that addresses the question")
- 看分布 → 看分组差异 → 看相关性
- 图必须 有颜色 + 有轴标签 + 有标题
- 选图类型要 match 自变量类型 (见 §Visualization 表)

Step 4 — Formulate Hypotheses ★

- 显式写出 H_0 和 H_1 (不能省!)
- 单尾 vs 双尾? (没方向预设就**双尾**, 单尾必须有先验理由)
- 显著性水平 $\alpha = 0.05$ (说明)

Step 5 — Check Assumptions ★

- 写出代码 + 显式解读结果, 不能只跑不写
- Shapiro-Wilk / Levene / Q-Q 残差图 → 决定 param vs non-param
- ⚠️ 必须写出结论: "Shapiro $p = 0.32 > 0.05$, 正态假设满足, 故选择 Student's t-test"

Step 6 — Run Test

- 写明**选择此 test 的理由** (引用 Step 4-5 的结论)
- 给完整 R 输出 + 翻译成自然语言

Step 7 — Post-hoc + Effect Size + CI ★

- ANOVA / KW / Friedman 显著 → Tukey / Dunn / 矫正后 Wilcoxon
- **必须报告 effect size** (Cohen's d / η^2 / Cramer's V) — 仅 p 不够
- **必须报告 95% CI** (`t.test()` 自带)

Step 8 — Interpret & Discuss ★

- 生物学 / 临床意义? (统计显著 ≠ 临床显著)
- Limitations (**不只是 sample size**, 见 §4.5)
- 改进建议 (机制实验 / 控制混杂 / power-backed n)

4.4 常见扣分点 (Dmytro 隐性 rubric)

❌ 错误做法	✅ 正确做法
直接 <code>t.test()</code> 不查 normality	先 Shapiro + Levene 再选检验
ANOVA 显著但不做 post-hoc	必做 Tukey / Dunn
只报 p-value	p + df + statistic + effect size • CI
改进只说"扩样"	给设计 / 对照 / 机制 + power 计算
假设违反但硬上参数	选 non-param / bootstrap / 变换
离群值盲删	先讨论原因再决定
H_0 / H_1 不写出来	显式列出
paired 数据当 unpaired 跑	看实验设计是否同一受试者重复测量
多重比较不矫正	Bonferroni / Holm / FDR
单尾 t 没说理由	必须有 先验 方向假设, 否则双尾
假设检查只跑代码不写结论	「p=X, 满足/违反, 因此选 Y」
选了某方法不为什么说不选另一个	「因 Shapiro 拒绝正态, 故弃 t-test 选 Mann-Whitney」

4.5 「改进方向」答题套话 (替代 "sample size") ★

按 5 大维度组织, 每题至少挑 3 个非扩样的方向:

1 实验设计 (Design)

- Randomization (随机化)
- Double-blinding (双盲)
- Longitudinal vs cross-sectional (纵向跟踪)
- Dose-response curve (剂量-反应)
- Crossover design (减少 between-subject 变异)

2 抽样 (Sampling)

- Stratified sampling (按性别 / 年龄 / 疾病分层)
- 收紧 inclusion/exclusion criteria
- Multi-center (多中心提升泛化性)
- Refine matching (病例对照匹配更严格)

3 测量与控制 (Measurement & Control)

- 更精确仪器 (减少 measurement error)
- 增加 covariates → ANCOVA / multivariate
- Positive + negative controls
- 重复测量取平均 (technical replicate)

4 分析方法 (Analysis)

- 用更强方法: `lmer()` 处理 nested data / repeated measures
- 多重比较校正
- Sensitivity analysis (敏感性分析)
- Bayesian approach (有先验信息时)

5 机制深入 (Mechanism)

- Western blot / IHC 验证蛋白水平
- scRNA-seq DEGs / pathway analysis
- CRISPR / RNAi 干预实验验证因果
- In vivo → in vitro 对照



标准答题模板:

"Beyond increasing sample size — which is the most resource-intensive solution — more efficient improvements include: (1) **[design 改进]**, (2) **[控制混杂]**, (3) **[机制验证]**. If sample size must be increased, power analysis (`pwr.t.test`) suggests **n = XX per group** to achieve power = 0.8 given effect size $d = X.X$ and $\alpha = 0.05$."

4.6 「为什么选 / 不选」论证模板 ★

每个 test 选择后, 写 2-3 句话论证:

模板: "Given that [assumption check 结果], and considering [实验设计], we selected [method X] over [alternative Y] because [reason]. [Method X] is appropriate here because [优点], whereas [Y] would [缺点 / 不适用原因]."

示例 1 (选 Welch's t over Student's):

"Levene's test $p = 0.012 < 0.05$ indicates unequal variances. We therefore use Welch's t-test rather than Student's t-test, as Welch's adjusts degrees of freedom to handle heteroscedasticity without requiring variance homogeneity."

示例 2 (选 Mann-Whitney over t-test):

"Shapiro-Wilk $p = 0.003 < 0.05$ rejects normality in group A, and $n = 12$ is too small to invoke CLT. We use Mann-Whitney U test, which compares rank distributions without normality assumption. The trade-off is slightly reduced power (~95% of t-test) and that we test median rather than mean differences — which we accept given the small skewed sample."

示例 3 (选 Bootstrap over Mann-Whitney):

"The data is non-normal with multiple outliers we cannot exclude on biological grounds. We use bootstrap (10,000 resamples) to estimate the sampling distribution of the median difference, giving a 95% CI that directly addresses the magnitude rather than only significance."

4.7 整体逻辑框架—图流 (考场最后一遍过)

1. 看数据	→	type, n, paired?, NA, outlier
2. 画图	→	分布 + 分组 + 关系 (回应题目!)
3. 写假设	→	H_0 , H_1 , 单/双尾, α
4. 查假设	→	Shapiro + Levene + 残差图 (写结论!)
5. 选 test	→	论证为什么选 / 为什么不选另一个 ★
6. 跑 test	→	完整输出 + 自然语言解读
7. Post-hoc	→	Effect size + CI (必做!)
8. 讨论	→	生物学意义 + Limitations + 改进 + Power

↑ 每一步都要在 Rmd 里有对应文字 + 代码 ↓



考前 1 分钟自查： AI 给我代码后，我有没有 — (1) 写出 H_0/H_1 ? (2) 查并解读 assumption? (3) 论证为什么选这个方法? (4) 做 post-hoc? (5) 报 effect size + CI? (6) Limitations 不只说扩样? **缺任何一个都丢分。**